제조 환경에서 자연어 작업 지시 기반 객체 탐지를 위한 Vision-Language PoC 연구

Vision2Language / 이신비 / 이신비, 조민채, 노현두

01 Introduction

기존의 로봇 인지 시스템은 사전에 정의된 ID나 규칙적이고 고정된 명령어에만 반응하여 작업 현장에서의 유동적인 지시를 처리하는 데 한계가 존재한다. 따라서 "오른쪽의 빨간 밸브가 필요해"와 같이 복합적인 정보를 이해하는 **REC(Referring Expression Comprehension)** 기술이 필수적으로 요구된다. 이에 본 연구는 자연어와 이미지를 결합한 **MDETR(Modulated DETR)** 모델을 도입하여 작업 현장에서의 인간-로봇 협업을 위한 인지 기술 PoC 연구를 수행한다.

02 Objectives

1. **데이터 분석 및 전처리**: AI-Hub '제조환경 사람-로봇 공유 작업 데이터'를 연구 목적에 맞춰, 모델 학습 가능한 포맷으로 변환 및 정제
2. **모델 구축 및 최적화**: Positive Map, ResNet-101과 RoBERTa를 결합한 End-to-End 멀티모달 모델 학습 및 파라미터 튜닝(Fine-tuning)
3. **PoC 검증**: 실제 제조 현장 이미지에서 복합적인 자연어 작업 지시를 이해하고 해당 객체의 위치를 정확히 추론(Object Detection, Visual Grounding)하는지 검증

03 Methods

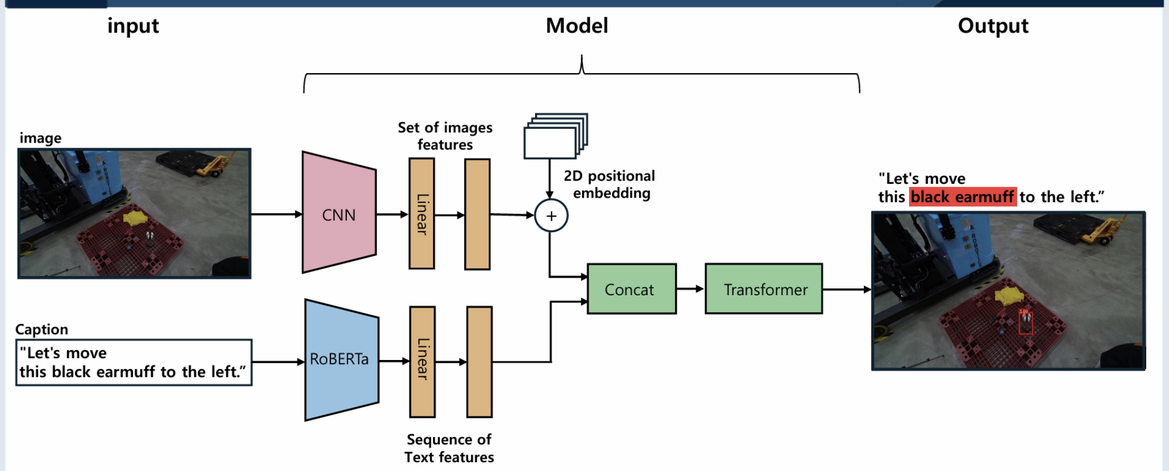

(1) Model Architecture

Backbone: ResNet-101 (Image) + RoBERTa (Text)

Fusion: 시각-언어 정보를 결합하여 Transformer Encoder-Decoder를 통해 객체 위치 예측

(2) Data Preprocessing & Additional Implementation

Filtering: Real RGB 이미지 선별(3D/Depth/Synthetic 제외)

Alignment: 한국어 지시문 번역 작업(Pre-trained RoBERTa와의 호환성 확보)

Optimization: Custom Collate Fn 및 Dynamic Positive Map 구현

04 Results

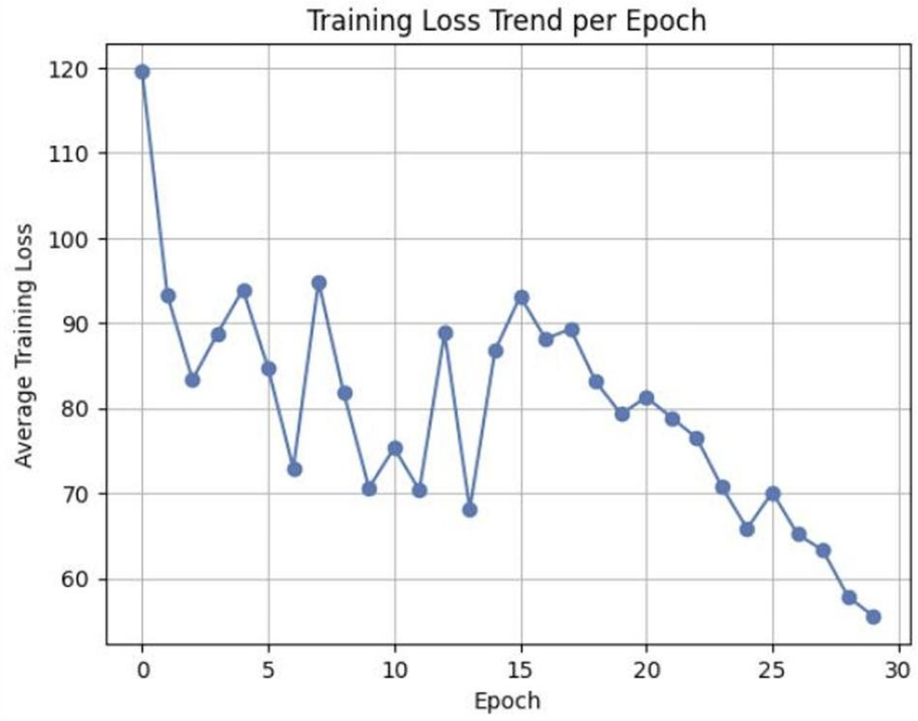

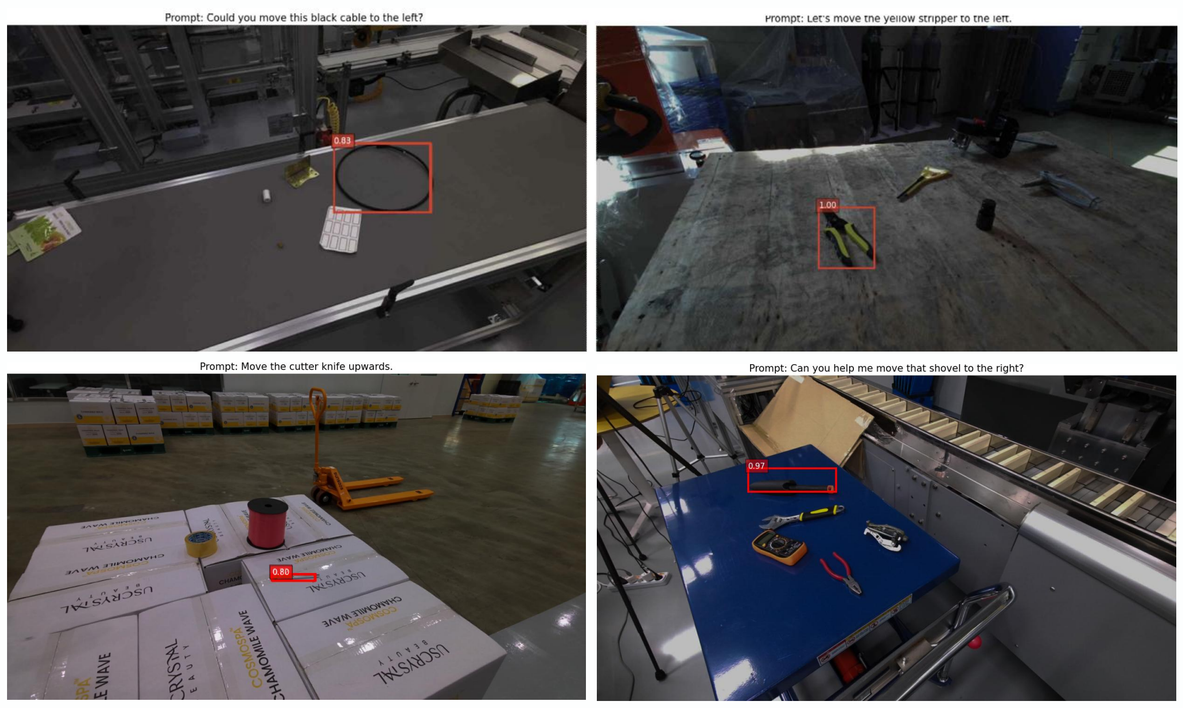

(1) Quantitative Analysis

초기 Loss(약 120)에서 학습이 진행됨에 따라 급격히 감소하며 최종적으로는 약 55까지 감소하여 적은 데이터양에도 불구하고 전이 학습(Transfer Learning)을 통해 유의미한 학습 패턴 확인.

(2) Qualitative Analysis

"이 검은색 케이블(this balck cable)", "노란색 니퍼(yellow stripper)" 등의 복합 명령어를 정확히 해석하여 복잡한 작업 환경 속에서도 텍스트가 지칭하는 특정 객체만을 정확히 Bounding Box로 검출 성공.

05 Conclusions and Discussions

본 연구는 AI-Hub 제조 데이터셋과 MDETR 모델을 결합하여 **작업 현장의 자연어 지시를 이해하는 객체 탐지 파이프라인**을 성공적으로 구축하였다. 특히, 이질적인 산업 데이터의 포맷 호환성 문제를 데이터 및 모델 분석을 통한 데이터 전처리와 추가적인 모델 구조 구축을 통해 해결하였으며, 전이 학습(Transfer Learning)을 통해 **적은 데이터양의 한계를 극복하여 유의미한 탐지 성능을 확보**하였다. 또한, 실제 제조 환경의 복합적인 지시어에 대한 정확한 Visual Grounding 성능을 확인함으로써, 기존의 고정된 명령 체계를 넘어선 직관적인 로봇 제어 인터페이스로서의 실효성을 입증하였다.

향후 연구에서는 현재의 번역 기반 프로세스를 넘어, KoBERT 등 한국어 특화 인코더를 도입하여 실시간 처리 속도와 언어 이해도를 한층 고도화할 수 있을 것으로 기대된다. 아울러 조명 변화나 가려짐(Occlusion)이 빈번한 현장 특성을 고려해 데이터 증강(Augmentation) 기법을 적용하여 더 많은 데이터를 확보한다면, 모델의 강건성과 범용성을 더욱 강화할 수 있을 것이다.

Reference

(1) AI Hub, "제조환경 사람-로봇 공유 작업 데이터," NIA, 2024.
(2) A. Kamath et al., "MDETR - Modulated Detection for End-to-End Multi-Modal Understanding," ICCV, 2021.N. Carion et al.,
(3) "End-to-End Object Detection with Transformers," ECCV, 2020.

한국외국어대학교 G-RISE 사업단
HUFS G-Regional Innovation System&Education Center